




BILD



PATCHES



EMBEDDINGS

WIE KI SEHEN LERNT

Multimodale Modelle erklärt — von innen.



VISION LANGUAGE MODELS • VLM

SWIPE →

PRE-2023

DIE ALTE METHODE

Das LLM sah das Bild nie selbst.



DAS PROBLEM

Das LLM arbeitet mit einer **Beschreibung des Bildes** — nicht mit dem Bild selbst.

Stille Post auf technischer Ebene.



LAYOUT

Tabellenstruktur geht verloren



DETAILS

Kleine Elemente ausgelassen



KONTEXT

Relationen fehlen

Genauigkeit war begrenzt — das Modell **riet**, statt zu sehen.
Das ändert sich mit nativer Vision.

NATIVE VISION INTEGRATION

Heute sieht das LLM das Bild wirklich.



1

PATCH-EXTRAKTION

Bild wird in kleine quadratische Patches unterteilt

2

VISION ENCODER

Ein Vision Transformer verarbeitet jeden Patch

3

PROJEKTION

Patch-Embeddings werden in den Text-Embedding-Raum projiziert

4

LLM VERARBEITET BEIDES

Text-Tokens und Bild-Embeddings — gemeinsam

Das LLM sieht **visuelle Struktur** —
nicht nur eine Beschreibung davon.
Text-Token und Bild-Patch: gleichwertig.


WAS DAS ERMÖGLICHT

Dinge, die früher undenkbar waren.



CHARTS DIREKT ANALYSIEREN

Keine manuelle Daten-Extraktion mehr



LAYOUT BLEIBT ERHALTEN

Tabellen-Struktur, Spalten, Zeilen



HANDSCHRIFT LESEN

Auch unstrukturierte Notizen



UI-ELEMENTE ERKENNEN

Buttons, Felder, Menüs auf Screenshots

Das Modell sieht, **wie** Daten zusammenhängen
— nicht nur, was draufsteht.

PRAXIS & GRENZEN

FRÜHER

- 1 Tabelle manuell extrahieren
- 2 Daten bereinigen
- 3 Format anpassen
- 4 Ergebnis hoffen



HEUTE

- 1 Screenshot machen
- 2 Prompt schreiben
- 3 Fertig.

DIE GRENZEN

- ⚠ Auflösung limitiert – kleiner Text und feine Details gehen verloren
- ⚠ Kein menschliches Sehen – bei komplexen Bildern kann das Modell halluzinieren

Faustregel: Je größer der Text im Screenshot, desto besser das Ergebnis.

MEIN WORKFLOW

Tabellen-Screenshots direkt in Grafiken umwandeln.
Das Modell erkennt **Spalten, Zeilen, Relationen**.



DUSTIN WALKER

GEN AI ENGINEER @ ALEXANDER THAMM

NÄCHSTE FRAGE

Nutzt ihr schon Screenshots mit KI?
Was funktioniert — was nicht?

Folge mir für mehr Insights aus echten AI-Projekten.

VERNETZEN →

