

LLM GRUNDLAGEN | TEIL 3



WARUM KANN CHATGPT NICHT DIE R IN

strawberry

TOKEN 101830

ZÄHLEN?

DIE SPRACHE DER LLMS: TOKENS

SWIPE →


LLMS KENNEN KEINE WÖRTER

Was ein LLM sieht, ist eine Liste von Zahlen.
Jede Zahl steht für ein **Token**.

TEXT HalliHallo, ich bin Dustin



TOKENIZER



“Dustin” = ein einzelner Token: **161250**

“HalliHallo” = drei Tokens

Keine Buchstaben. Keine Wörter.
Nur **Nummern**.

WARUM TOKENS STATT WÖRTER?

Die Menge an möglichen Wörtern ist absurd.

151.000 | **DUDEN**
Stichwörter

~2 MIO. | **DEUTSCH GESAMT**
mit allen Formen & Komposita

??? | **ALLE SPRACHEN**
Kyrillisch, Mandarin, Arabisch, Tamil, ...

+3.600 | **EMOJIS**
🎲 🐱 🚀 🍲 🌙 🧩



LÖSUNG: TOKENIZER

200.000

Tokens im Vokabular von GPT-5

1,6 Tokens $\approx$ 1 Wort • 1 Token $\approx$ 4 Buchstaben

ENGLISCH IST BILLIGER

Der Tokenizer ist für Englisch optimiert.
Andere Sprachen brauchen mehr Tokens.

ENGLISCH

105

468 Zeichen • 105 Tokens

NORWEGISCH

157

465 Zeichen • 157 Tokens

+50%

ARABISCH

286

402 Zeichen • 286 Tokens

+172%

Gleicher Inhalt, aber auf Arabisch
fast 3x so teuer wie auf Englisch.

TOKENS TRAGEN BEDEUTUNG

SEMANTISCH NAH

KING ↔ PRINCE

SEMANTISCH FERN

PRICE ↔ PRINCE

Nur ein Buchstabe Unterschied, aber ein LLM
sieht keine Buchstaben. Nur Token-Nummern
mit gelernter Bedeutung.

DARUM KANN EIN LLM DIE R NICHT ZÄHLEN

WAS WIR SEHEN

s-t-r-a-w-b-e-r-r-y

VS.

WAS EIN LLM SIEHT

101830

MEIN NAME IM GPT-5 TOKENIZER

Dustin = **161250**



DUSTIN WALKER

GEN AI ENGINEER @ ALEXANDER THAMM

Ist euer Name auch ein eigener Token?

Checkt es: tiktokenizer.vercel.app

VERNETZEN →